

## طراحی، توسعه و ارزیابی سامانه ترجمه ماشینی عصبی تخصصی در حوزه ورزشی

### شرح پروژه

این پروژه با هدف طراحی و ارزیابی یک سامانه ترجمه ماشینی عصبی آگاه از بافت (Context-Aware Neural Machine Translation) در حوزه تخصصی ورزشی تعریف شده است. در داده‌های این پروژه، هر نمونه صرفاً شامل یک زوج جمله مبدأ و مقصد نیست، بلکه علاوه بر جمله اصلی، چند بخش بافتی نیز در اختیار مدل قرار می‌گیرد تا فرایند ترجمه با اتکا به اطلاعات پیرامونی انجام شود. به‌طور مشخص، هر رکورد داده شامل جمله مبدأ (source)، ترجمه مرجع (target) و چند قطعه بافت متنی مرتبط (context\_1، context\_2 و context\_3) است.

بر این اساس، مسئله اصلی پروژه صرفاً تولید ترجمه جمله نیست، بلکه بررسی این موضوع است که استفاده از بافت متنی اطراف جمله تا چه اندازه می‌تواند کیفیت ترجمه در متون ورزشی را بهبود دهد. این موضوع به‌ویژه در ترجمه اصطلاحات تخصصی، عبارات چندمعنایی، ارجاعات درون‌متنی، پیوستگی معنایی و انتخاب معادل‌های دقیق در زبان مقصد اهمیت دارد. در این پروژه، از دانشجو انتظار می‌رود یک یا چند مدل ترجمه ماشینی عصبی را طراحی، پیاده‌سازی و ارزیابی کند؛ به‌گونه‌ای که دست‌کم یکی از مدل‌ها بتواند اطلاعات بافتی را به‌صورت صریح در فرایند ترجمه به کار گیرد. همچنین دانشجو باید عملکرد مدل پایه بدون بافت را با مدل آگاه از بافت مقایسه کند و نشان دهد که استفاده از اطلاعات پیرامونی در چه شرایطی مفید، خنثی یا حتی مسئله‌ساز است. خروجی نهایی پروژه باید شامل سه مؤلفه اصلی باشد:

1. طراحی فنی سامانه ترجمه: شامل تعریف دقیق ورودی‌ها، نحوه استفاده از بافت، معماری مدل و فرایند آموزش.
  2. ارزیابی تجربی و قابل استناد: شامل استفاده از معیارهای استاندارد ترجمه ماشینی، مقایسه مدل‌ها و گزارش نتایج کمی.
  3. تحلیل علمی خطاها و رفتار مدل: شامل بررسی نمونه‌های واقعی، تحلیل نقاط قوت و ضعف، و تبیین نقش بافت در بهبود یا افت کیفیت ترجمه.
- این پروژه به‌گونه‌ای طراحی شده است که برای دانشجویان کارشناسی‌ارشد، یک تمرین پژوهشی-کاربردی پیشرفته در حوزه ترجمه ماشینی محسوب شود و برای دانشجویان دکتری نیز قابلیت توسعه به یک مطالعه پژوهشی عمیق‌تر در زمینه ترجمه ماشینی زمینه‌محور، سازگاری دامنه‌ای و تحلیل رفتار مدل‌های عصبی را داشته باشد.

### اهداف پروژه

این پروژه با اهداف علمی و اجرایی زیر تعریف می‌شود:

- بررسی ساختار و ویژگی‌های زبانی متون ورزشی در قالب داده‌های ترجمه زمینه‌محور؛
- تحلیل نقش بافت متنی در ترجمه دقیق‌تر جملات تخصصی حوزه ورزش؛
- طراحی و پیاده‌سازی یک مدل پایه برای ترجمه ماشینی در سطح جمله، بدون استفاده از بافت؛
- طراحی و پیاده‌سازی یک مدل پیشرفته‌تر که بتواند از اطلاعات موجود در context\_1، context\_2 و context\_3 در فرایند ترجمه استفاده کند؛
- مقایسه تجربی عملکرد مدل‌های بدون بافت و آگاه از بافت با استفاده از معیارهای استاندارد ارزیابی ترجمه ماشینی؛
- بررسی میزان تأثیر بافت در ترجمه اصطلاحات تخصصی، ترکیبات چندکلمه‌ای، ارجاعات معنایی و واژه‌های وابسته به دامنه ورزش؛
- تحلیل خطاهای ترجمه و دسته‌بندی مواردی که در آن‌ها بافت باعث بهبود، عدم تغییر یا افت کیفیت خروجی شده است؛
- ارائه یک گزارش پژوهشی حرفه‌ای، ساختاریافته و قابل استناد در سطح تحصیلات تکمیلی.

## مراحل اجرایی پروژه

برای اجرای این پروژه، ابتدا مجموعه داده مورد نیاز را از نشانی زیر دریافت کنید و سپس مراحل تعریف شده را به ترتیب انجام دهد. آدرس دریافت داده ها:

<https://gitlab.chabokan.net/mohammad29282928/advance-nlp-dr-safari.git>

پس از دریافت داده ها، مراحل زیر را به ترتیب انجام دهید.

### ۱. آماده سازی و تحلیل اولیه داده ها

- در مرحله نخست، دانشجو باید داده های ارائه شده را بررسی و برای استفاده در سامانه ترجمه ماشینی آماده سازی کند. این مرحله نقش مهمی در کیفیت نهایی مدل خواهد داشت. اقدامات مورد انتظار در این مرحله عبارتند از:
- انجام پیش پردازش های استاندارد متون شامل **نرمال سازی (Normalization)**، **توکن سازی (Tokenization)** و در صورت نیاز **هم تراز سازی جملات (Sentence Alignment)**.
  - بررسی ساختار داده ها و تحلیل آماری مجموعه داده، از جمله: توزیع طول جملات، واژگان پرتکرار، تنوع واژگانی و میزان حضور اصطلاحات تخصصی حوزه ورزش.
  - استخراج و مستند سازی فهرستی از **واژگان و اصطلاحات تخصصی احتمالی** که در متون ورزشی به کار رفته اند.
  - تهیه یک گزارش کوتاه و دقیق درباره ویژگی های زبانی داده ها، از جمله سبک نوشتاری، نوع اصطلاحات تخصصی و چالش های احتمالی ترجمه در این دامنه.

### ۲. طراحی و آموزش سه مدل ترجمه

در این مرحله، دانشجو باید حداقل سه مدل ترجمه ماشینی را طراحی، پیاده سازی و آموزش دهد. هدف از این بخش، مقایسه عملکرد رویکردهای مختلف در ترجمه متون تخصصی حوزه ورزش است.

#### مدل ۱ - مدل پایه (Baseline NMT)

در این مرحله یک سیستم ترجمه مبنا پیاده سازی می شود که به عنوان خط پایه برای مقایسه سایر مدل ها مورد استفاده قرار می گیرد. مدل پایه می تواند شامل یکی از گزینه های زیر باشد:

- یک معماری Transformer استاندارد آموزش داده شده روی داده های پروژه؛
  - یا یک مدل ترجمه عمومی از پیش آموزش داده شده که بدون ریزتنظیم دامنه ای مورد استفاده قرار می گیرد.
- هدف از این مرحله ایجاد یک **خط مبنای قابل مقایسه** برای ارزیابی اثر روش های پیشرفته تر است.

#### مدل ۲ - مدل تخصصی شده برای حوزه ورزش (Domain-Adapted NMT)

در این مرحله، دانشجو باید یک مدل ترجمه عمومی را برای دامنه متون ورزشی **تنظیم دقیق (Fine-tune)** کند تا مدل بتواند اصطلاحات و ساختارهای زبانی خاص این حوزه را بهتر ترجمه کند. برخی از تکنیک های پیشنهادی برای این مرحله عبارتند از موارد زیر (به کارگیری یک یا چند مورد از این روش ها):

- Domain Tagging برای مشخص کردن دامنه متن در ورودی مدل
- Fine-Tuning مدل های از پیش آموزش داده شده روی داده های دامنه ورزش
- Vocabulary Adaptation یا تطبیق واژگان برای پوشش بهتر اصطلاحات تخصصی
- Mixed Training با ترکیب داده های عمومی و داده های تخصصی

#### مدل ۳ - مدل پیشرفته (Advanced NMT)

در مرحله سوم، دانشجو باید یک مدل پیشرفته تر طراحی کند که حداقل از یکی از تکنیک های بهبود پیشرفته در ترجمه ماشینی استفاده کند.

روش‌های پیشنهادی برای این مرحله شامل موارد زیر است:

- Back-Translation برای افزایش داده آموزشی
- Terminology-Constrained Decoding برای کنترل ترجمه اصطلاحات تخصصی
- استفاده از مدل‌های زبانی بزرگ به عنوان کمک‌رسان در ترجمه (LLM-Assisted NMT)
- استفاده از روش‌های LoRA یا QLoRA برای سازگاری دامنه‌ای مدل‌های بزرگ

هدف این مرحله بررسی این موضوع است که آیا استفاده از روش‌های پیشرفته می‌تواند کیفیت ترجمه متون تخصصی را به‌طور معناداری بهبود دهد یا خیر.

### ۳. ارزیابی مدل‌ها

پس از آموزش مدل‌ها، دانشجو باید عملکرد آن‌ها را با استفاده از معیارهای استاندارد ارزیابی ترجمه ماشینی بررسی کند.

- معیارهای پیشنهادی شامل موارد زیر است: 1) BLEU ، 2) COMET ، 3) chrF++ (4) BERTScore
- علاوه بر ارزیابی خودکار، دانشجو باید یک **ارزیابی انسانی محدود** نیز انجام دهد. در این بخش حداقل ۲۰ نمونه ترجمه باید به‌صورت دستی بررسی شوند و کیفیت ترجمه بر اساس یکی از چارچوب‌های زیر ارزیابی گردد: 1) Direct Assessment (DA) یا 2) Multidimensional Quality Metrics (MQM). نتایج ارزیابی باید به‌صورت کمی (اعداد و شاخص‌ها) و کیفی (توضیح و تحلیل) گزارش شوند.

### ۴. تحلیل خطا (Error Analysis)

در این مرحله، دانشجو باید رفتار مدل‌های ترجمه را به‌صورت دقیق تحلیل کند. برای این منظور، لازم است:

- حداقل 20 نمونه ترجمه از خروجی مدل‌ها انتخاب و بررسی شوند.
  - خطاهای مشاهده‌شده دسته‌بندی شوند. دسته‌بندی پیشنهادی شامل موارد زیر است:
- |                   |                                |                                      |
|-------------------|--------------------------------|--------------------------------------|
| 1. خطاهای معنایی  | 2. ترجمه نادرست اصطلاحات تخصصی | 3. ابهام معنایی                      |
| 4. خطاهای واژگانی | 5. خطاهای دستوری               | 6. ترجمه نادرست نام‌ها یا موجودیت‌ها |

در ادامه، دانشجو باید توضیح دهد که **ریشه این خطاها چیست** و این خطاها به کدام بخش از مدل یا داده‌های آموزشی مربوط می‌شوند.

### ۵. ارائه راهکارهای بهبود

بر اساس نتایج مرحله تحلیل خطا، دانشجو باید دست‌کم **دو روش بهبود** را طراحی، پیاده‌سازی و ارزیابی کند.

نمونه‌هایی از روش‌های قابل استفاده عبارت‌اند از:

- افزودن یک **واژه‌نامه یا فهرست اصطلاحات تخصصی ورزشی** به فرایند ترجمه
  - استفاده از Data Augmentation برای افزایش تنوع داده‌ها
  - استفاده از Beam Search با **قیود معنایی یا واژگانی**
  - بازآموزی مدل با تمرکز بر نمونه‌های دشوار (Hard Example Training)
- دانشجو باید نشان دهد که این روش‌ها چه تأثیری بر کیفیت ترجمه داشته‌اند و آیا بهبود معناداری در نتایج ایجاد شده است یا خیر.

### بخش اختیاری با نمره اضافی

این بخش اختیاری و توصیه شده است و می‌تواند پروژه را از سطح یک تمرین معمولی به سطح یک مطالعه پژوهشی پیشرفته ارتقا دهد. در این بخش از دانشجو انتظار می‌رود که فراتر از فرایند اصلی ترجمه ماشینی، برخی چالش‌ها و پدیده‌های مهم در حوزه ترجمه ماشینی زمینه‌محور را بررسی و تحلیل کند. این تحلیل‌ها باید هم **نظری** و هم **تجربی** باشند.

موارد پیشنهادی برای این بخش عبارت‌اند از:

- **بررسی پدیده Domain Shift در متون ورزشی:** دانشجو باید بررسی کند که مدل طراحی‌شده در زیرحوزه‌های مختلف ورزش (مانند فوتبال، والیبال، رشته‌های رزمی و غیره) چه میزان پایداری دارد و آیا تغییر زیرحوزه موجب کاهش عملکرد مدل می‌شود یا خیر. این تحلیل می‌تواند شامل مقایسه BLEU یا COMET میان زیردامنه‌ها باشد.
  - **تحلیل ترجمه در سطح اسناد (Document-Level NMT):** دانشجو باید بررسی کند که در صورت استفاده از مدل در سطح سند (نه صرفاً جمله)، چه تغییری در پیوستگی ترجمه، یکپارچگی ارجاعات و انسجام زبانی ایجاد می‌شود. این بخش به‌ویژه برای داده‌هایی که شامل context هستند اهمیت ویژه‌ای دارد.
  - **بررسی تأثیر داده‌های زبانی نویزی (Noisy Text):** نمونه‌هایی از متون ورزشی، مانند کامنت هواداران، شامل نویز، غلط‌های تایپی، ساختار غیررسمی و واژگان عامیانه هستند. دانشجو می‌تواند بررسی کند که مدل در مواجهه با چنین داده‌هایی چه رفتار یا چالش‌هایی دارد.
  - **ارزیابی قابلیت انتقال مدل میان زبان‌ها (Cross-Lingual Transfer):** در صورتی که داده جانبی در زبان‌های دیگر موجود باشد (یا با روش‌هایی مانند back-translation تولید شود)، دانشجو می‌تواند بررسی کند که آیا مدل توانایی انتقال دانش زبانی یا مفهومی میان زبان‌ها را دارد و تا چه اندازه ساختار مدل در این حالت پایدار باقی می‌ماند.
- در این بخش، انتظار می‌رود دانشجو تحلیل‌های خود را همراه با نمونه‌های واقعی، نمودارهای مقایسه‌ای و تبیین‌های نظری ارائه کند.

## گزارش نهایی

گزارش نهایی باید حرفه‌ای، دقیق، منسجم و بدون ابهام باشد و ساختاری مشابه مقالات پژوهشی معتبر داشته باشد. این گزارش حداقل باید شامل بخش‌های زیر باشد:

1. **مقدمه علمی:** شامل معرفی مسئله، اهمیت ترجمه ماشینی زمینه‌محور، چالش‌های موجود در ترجمه متون ورزشی، و اهداف پروژه.
2. **توصیف و تحلیل داده:** شامل معرفی ساختار داده‌ها (context, target, source)، آمارهای کلیدی، ویژگی‌های زبانی، و چالش‌های مرتبط با دامنه ورزش.
3. **معماری مدل‌ها:** توضیح کامل درباره سه مدل پیاده‌سازی‌شده (Advanced NMT, Domain-Adapted, Baseline)، همراه با جزئیات معماری، پارامترهای آموزشی، و نحوه استفاده از اطلاعات بافت.
4. **نتایج کمی:** ارائه دقیق معیارهای BLEU، COMET، chrF++ و BERTScore برای هر مدل، همراه با جدول‌ها و نمودارهای مقایسه‌ای.
5. **تحلیل‌های کیفی:** بررسی نمونه‌های ترجمه‌شده و تحلیل تفاوت‌های معنایی، واژگانی و انسجامی میان مدل‌ها.
6. **تحلیل خطا:** دسته‌بندی خطاها (معنایی، واژگانی، اصطلاحات، دستور، ابهام، موجودیت‌ها) و تحلیل ریشه خطاها همراه با مثال‌های واقعی.
7. **پیشنهادها و جمع‌بندی:** شامل نتیجه‌گیری درباره عملکرد مدل‌ها، تأثیر بافت، پیشنهادهایی برای پژوهش‌های آینده، و مسیرهای احتمالی بهبود.
8. **شکل‌ها، جدول‌ها و نمودارها:** باید شماره‌گذاری دقیق داشته باشند؛ عنوان مناسب و شفاف داشته باشند و در متن گزارش ارجاع داده شوند.

## نام‌گذاری و قالب فایل نهایی پروژه

فایل نهایی باید به‌صورت زیپ شامل کدها و مستندات تحویل داده شود. نام فایل باید شامل نام، نام خانوادگی و شماره دانشجویی باشد و این سه مورد باید با کاراکتر خط تیره (-) از هم جدا شوند (FirstName-LastName-StudentID.pdf). این قالب نام‌گذاری الزامی است.

موفق باشید